Trabajo práctico final: Deep Learning

Identificación de etiquetas de medicamentos a través de imágenes

Nombre y apellido: Matías Premio Prado

Email: mpremio@itba.edu.ar.

Cuatrimestre: Primer cuatrimestre, 2024.

Materia: Deep Learning (M 1.11)

Cuerpo docente:

- Donizetti, Paolo Alberto
- Chamorro, Lionel
- Visco Comandini, Filippo

Índice

Introducción 3
Objetivo del trabajo 4
Propuesta de valor 4
Análisis preliminar de mercado 4
Resumen del plan de implementación 5
Desarrollo (Parte A): Entrenamiento y validación del algoritmo 6
Desarrollo (Parte B): Desarrollo de la aplicación en React Native 9
Desarrollo (Parte C): Conexión de la aplicación con el modelo 10

Introducción

Es de público conocimiento que el manejo del stock en las farmacias de la provincia de Buenos Aires presenta múltiples desafíos que afectan tanto a los profesionales de la salud como a los pacientes.
El procedimiento habitual de venta de medicamentos dentro de una farmacia consiste en los siguientes pasos:

1. El cliente presenta la prescripción médica o solicita verbalmente el medicamento deseado.
2. Si el farmacéutico recibe una prescripción médica, se realiza el proceso típico de validación de la misma, en el que se le pide al cliente datos relacionados con su obra social o prepaga, así como sus datos personales (nombre y apellido, firma y DNI). Si la solicitud es particular, es decir, no hay una prescripción médica, se procede directamente al paso 3.
3. El farmacéutico registra la solicitud de compra en el sistema.
4. Si el medicamento está al alcance del farmacéutico, no hay inconvenientes. Sin embargo, en muchos casos, el medicamento se encuentra en un lugar diferente al que se encuentra el farmacéutico. Por ejemplo, en muchas farmacias de la provincia de Buenos Aires, los medicamentos se almacenan en un piso superior, y se utiliza un sistema de tobogán para enviarlos a la planta baja.
5. El farmacéutico recibe el medicamento y, si es necesario, realiza alguna operación adicional, como por ejemplo recortar el código de barras de la caja del medicamento para pegarlo posteriormente en la prescripción médica.
6. El farmacéutico indica al paciente que se dirija a otra estación dentro de la farmacia, donde comúnmente se paga la medicación y el personal de la farmacia entrega el paquete.

En este trabajo se desea estudiar específicamente lo que sucede en el punto 4. Este método es propenso a errores, tales como el envío de la medicación incorrecta, medicación vencida o de la marca equivocada, lo cual conlleva varias complicaciones:

A. Pérdida de tiempo debido a la necesidad de repetir la solicitud de la medicación correcta.
B. Riesgo de deterioro de la medicación que permanece en el tobogán, especialmente si requiere condiciones específicas de conservación.
C. Costos adicionales para la farmacia al entregar una marca más cara que la solicitada por el paciente.
D. Entrega de una medicación que no está apta para consumo, lo cual puede generar daños en la salud del paciente.

Objetivo del trabajo

En este trabajo, se propone diseñar un algoritmo basado en deep learning que pueda identificar si el medicamento que la persona encargada de gestionar el stock está a punto de mandar al farmacéutico es correcto.
El sistema utilizará un sistema del estilo pasa / no pasa, en donde si al tomar una foto del medicamento que se quiere mandar se detecta que el nombre coincide con el medicamento solicitado, se pone en verde diciendo que el medicamento es correcto o rojo si no coincide con el medicamento solicitado y requiere revisión.

Propuesta de valor

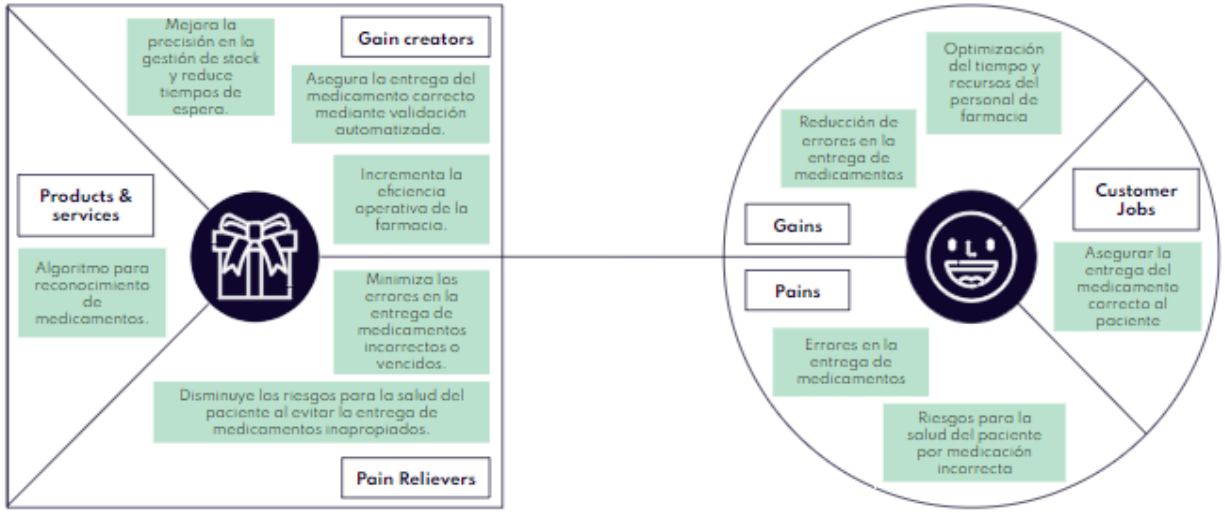

Análisis preliminar de mercado

Para empezar, se tiene que cuantificar el mercado. El modelo de negocio inicial que se plantea en este caso es B2B, se le estará cobrando a las farmacias un fee por utilizar la herramienta. Teniendo en cuenta que no se tiene un número claro de la cantidad de farmacias que hay en la provincia de Buenos Aires, se tomaron las siguientes suposiciones:

- Población Actual de la Provincia de Buenos Aires: Aproximadamente 17 millones de habitantes.
- Promedio de Farmacias por cada 10,000 Habitantes: En Argentina, hay alrededor de 1 farmacia por cada 2,000 habitantes en áreas urbanas. Asumiendo un ratio similar para la provincia de Buenos Aires nos da un mercado total de 8500 farmacias.

Con respecto a la estrategia de precios que se tomará en este caso, se opta por una estrategia de precios progresiva:

- Fee Inicial: Gratis durante los primeros 6 meses.
- Fee en el Segundo Semestre del Primer Año: $1 USD por farmacia al mes.
- Fee en el Segundo Año: $2 USD por farmacia al mes.
- Fee a partir del Tercer Año: $5 USD por farmacia al mes.

Si se asume que en 5 años se logrará tener un 20% del mercado total:

Período (años)	N° de farmacias	Fee por mes (usd)	Ingresos por mes (usd)	Ingresos anualizados (usd)
0 - 0.5	50	$0	$0	$0
0.5 - 1	100	$1	$100	$1.200
1 - 2	200	$2	$400	$4.800
2 - 3	400	$5	$2.000	$24.000
3 - 4	800	$5	$4.000	$48.000
4 - 5	1.600	$5	$8.000	$96.000

Resumen del plan de implementación

1. La estrategia de captación Inicial será el período de prueba gratuita: Se ofrecerá el servicio gratuito durante los primeros 6 meses para captar una base amplia de farmacias.
2. Con respecto a la estrategia de marketing y publicidad, se hará una fuerte inversión en campañas en redes sociales, Google Ads y plataformas especializadas en farmacia, donde se va a destacar el período de prueba gratuito. Será clave poder utilizar testimonios y casos de éxito para atraer a nuevas farmacias.
3. Retención de clientes: Se buscará crear fidelización con nuestros clientes a través de:
    - Soporte Continuo.
    - Feedback y Mejoras: Se implementará un sistema de retroalimentación para mejorar el producto basado en las sugerencias de los clientes.
    - Programas de Fidelización: Se creará un programa de recompensas para farmacias que refieran a otras o que mantengan una suscripción a largo plazo.
4. Con respecto a las estrategias de expansión, no se descarta en el largo plazo la escalabilidad regional. Una vez consolidada la presencia en Buenos Aires, considerar la expansión a otras provincias argentinas y países cercanos es posible. También se podrán considerar otros modelos de negocios, cómo la

monetización por la utilización de la base de datos de medicamentos que se irá creando con la utilización del producto.

5. Con respecto a la estrategia financiera, lo más importante de este modelo de negocio será mantener los costos fijos bajos, debido a que se plantea un escenario de pocos ingresos en los primeros 2 años.

Desarrollo (Parte A): Entrenamiento y validación del algoritmo

1) **Instalación y Configuración Inicial**: Se instala la versión específica de TensorFlow (2.9.1) y se importan las bibliotecas necesarias para el manejo de datos, visualización y construcción del modelo de deep learning.
2) **Conexión a Google Drive y Preparación de Datos**: Se conecta Google Drive al entorno de trabajo para acceder a los datos de entrenamiento almacenados en un archivo zip. Luego, se extraen los datos en una carpeta del entorno y se preparan las rutas y etiquetas de las imágenes para su procesamiento.
3) **División de Datos**: Los datos se dividen en tres conjuntos: entrenamiento (80%), validación (12%) y prueba (8%) utilizando train_test_split.
4) **Generación de Datos Aumentados**: Se utilizan ImageDataGenerator de Keras para aplicar data augmentation y generar lotes de imágenes para los conjuntos de entrenamiento, validación y prueba.
5) **Visualización de Datos**: Se visualizan ejemplos de las imágenes de entrenamiento con sus respectivas etiquetas para asegurarse de que los datos estén correctamente cargados y etiquetados.
6) **Construcción del Modelo**: Se utiliza la arquitectura preentrenada EfficientNetB1 como base del modelo. Se añade una capa de normalización, una capa densa con regularización L1 y L2, una capa de Dropout para reducir el sobreajuste, y finalmente una capa de salida softmax para clasificación multiclase.
7) **Compilación del Modelo**: El modelo se compila utilizando el optimizador Adamax y la pérdida de entropía cruzada categórica para el aprendizaje de clasificación multiclase.
8) **Entrenamiento del Modelo**: Se entrena el modelo utilizando el generador de datos de entrenamiento y se valida utilizando el conjunto de validación. Se registra el historial de pérdidas y precisión durante las épocas de entrenamiento. Se utilizaron 3 épocas.
9) **Evaluación y Guardado del Modelo**: El modelo se evalúa en los conjuntos de entrenamiento, validación y prueba para obtener la precisión y la pérdida. Posteriormente, se guarda el modelo entrenado en Google Drive.
    a) **Carga del Modelo y Predicción**: Se carga el modelo guardado desde Google Drive y se realizan predicciones en el conjunto de prueba.
    b) **Visualización de Resultados**: Se construye y visualiza una matriz de confusión para analizar el rendimiento del modelo y se genera un

informe de clasificación para evaluar las métricas de precisión, recall y F1 por clase.

Luego de 3 épocas, los resultados preliminares son los siguientes:

1. **Alta precisión**: En la primera época, el modelo ya logra una precisión alta en los conjuntos de entrenamiento (82.67%) y validación (98.17%). Esto indica que el modelo comienza con una buena capacidad de clasificación.
2. **Mejora Continua**: A lo largo de las épocas, tanto la precisión del entrenamiento como la de validación mejoran significativamente. Para la tercera época, la precisión alcanza el 99.39% en el entrenamiento y el 99.67% en la validación, mostrando que el modelo aprende efectivamente.
3. **Reducción Consistente de la pérdida**: La pérdida (loss) disminuye de manera constante con cada época. La pérdida de entrenamiento se reduce de 6.8690 a 2.6008, y la pérdida de validación baja de 5.2279 a 2.0375, lo que sugiere una mejora en la capacidad del modelo para ajustar los datos.
4. **Posible sobreajuste**: La pérdida y precisión en el conjunto de validación son extremadamente altas (99.33% y 99.67%), lo que podría ser indicativo de un posible sobreajuste si la precisión es mucho mayor que en el conjunto de prueba. Sería importante evaluar el modelo en datos no vistos (conjunto de prueba) para confirmar si generaliza bien.

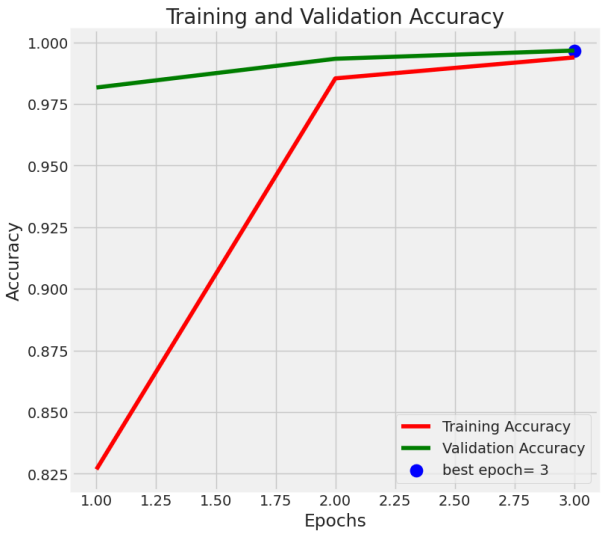

Los resultados de la prueba fueron los siguientes:

- **Precisión muy alta en todos los conjuntos**: El modelo alcanza una precisión perfecta (100%) en el conjunto de entrenamiento y una precisión muy alta en los conjuntos de validación (99.69%) y prueba (99.50%). Esto indica que el modelo tiene un rendimiento excelente y una alta capacidad de clasificación en datos previamente no vistos.

- **Pérdidas consistentes**: Las pérdidas son consistentes y bajas en los tres conjuntos: entrenamiento (2.0255), validación (2.0372) y prueba (2.0399). La similitud en las pérdidas sugiere que el modelo no está sobreajustado y generaliza bien a los datos de prueba.
- **Buena generalización del modelo**: Dado que la precisión en los conjuntos de validación y prueba es muy alta y cercana a la del conjunto de entrenamiento, el modelo demuestra una buena capacidad de generalización.
- **Modelo bien ajustado**: El desempeño casi perfecto en los datos de prueba indica que el modelo está bien ajustado y es capaz de manejar casos no vistos de manera efectiva.

Los resultados de la matriz de confusión son los siguientes:

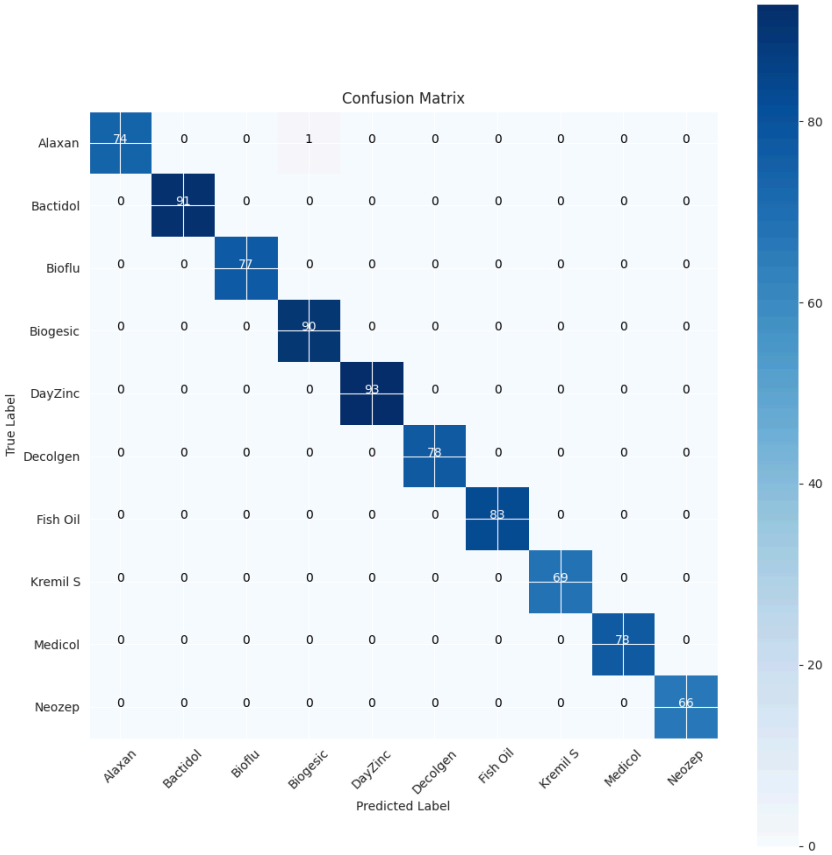

- **Precisión alta en general**: La mayoría de las clases muestran una alta precisión de clasificación, ya que la mayoría de los elementos se encuentran en la diagonal principal. Por ejemplo, "Bactidol" tiene 91 clasificaciones correctas y "DayZinc" tiene 93, lo que sugiere que el modelo clasifica correctamente estas clases la mayor parte del tiempo.
- **Clasificaciones incorrectas mínimas**: Hay muy pocos errores de clasificación. Por ejemplo, "Alaxan" tiene una clasificación incorrecta con "Decolgen" (1 error) y "Medicol" tiene un error de clasificación con "Neozep".

- **Clases con menor precisión**: Algunas clases, como "Kremil S" (69 clasificaciones correctas) y "Neozep" (66 clasificaciones correctas), tienen menos clasificaciones correctas en comparación con otras clases.
- **No hay confusión significativa entre clases**: No hay indicios de una confusión significativa entre las clases, ya que la mayoría de las clasificaciones incorrectas son mínimas (por ejemplo, solo 1 error en varios casos).

Desarrollo (Parte B): Desarrollo de la aplicación en React Native

La estructura de la aplicación es muy simple teniendo en cuenta que se trata de un MVP. La aplicación en React Native está compuesta por tres archivos principales: App.js, ValidationScreen.js, y ContactScreen.js.

1. **App.js:** Este archivo maneja la navegación entre las pantallas de bienvenida, validación, y contacto

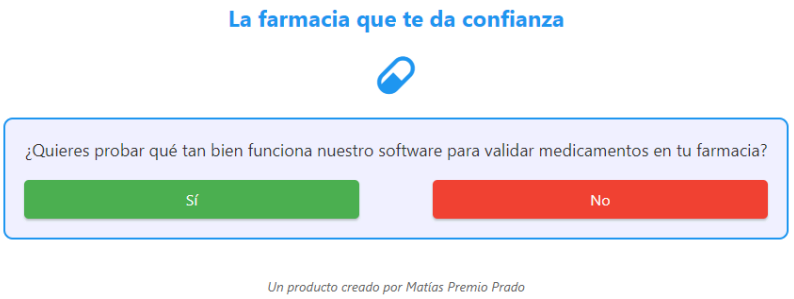

.

2. **ValidationScreen.js:** Esta pantalla permite al usuario tomar una foto del medicamento y validar que eligió el medicamento correcto.

3. **ContactScreen.js:** Esta pantalla está diseñada para proporcionar al usuario la información de contacto en caso de que no desee probar la funcionalidad de validación de medicamentos.

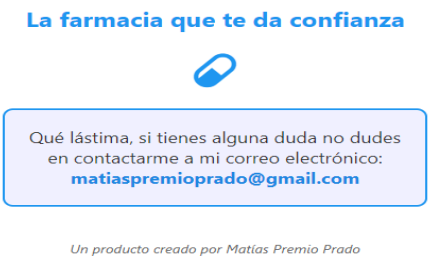

La aplicación utiliza react-native-vector-icons para íconos, expo-image-picker para tomar fotos y react-navigation para manejar la navegación entre las pantallas. La validación del medicamento es simulada para ilustrar el flujo completo.

Desarrollo (Parte C): Conexión de la aplicación con el modelo

Cómo siguiente etapa, se debería crear la conexión entre la aplicación creada en React y el modelo entrenado.

Los pasos a realizar serán los siguientes:

1. Configurar el entorno e instalar paquetes necesarios (como Flask).
2. Crear el servidor Flask para manejar las solicitudes de predicción.
3. Exponer el servidor públicamente usando ngrok para obtener una URL accesible.
4. Probar el servidor para asegurarse de que funciona correctamente.
5. Conectar la aplicación utilizando la URL pública proporcionada por ngrok.